

IA embarquée pour la perception des véhicules autonomes en logistique hospitalière

PRI 2026-2027 · Projet 2 · Encadrement : Moïse DJOKO-KOUAM
Note de synthèse — version 1, septembre 2026

État des lieux de l'existant, comparaison des modèles et choix technologiques. Le détail complet figure dans le rapport associé (39 p.).

1. Le problème, reformulé

Problématique du sujet : concevoir une IA de perception *performante, frugale et apte au déploiement embarqué*, qui transforme des informations de perception hétérogènes en une représentation structurée de l'environnement du véhicule autonome (VA).

Le point structurant : le module de perception n'est pas le produit final — son client est une **IA de décision**, hors périmètre. Le livrable réel est donc un **contrat d'interface** : un flux de données structurées, horodatées et **assorties d'un niveau de confiance**.

Sortie attendue	Nature	Produite par
a — Obstacle détecté / position / distance	Géométrique + classe	Détection + fusion LiDAR
b — Personne présente	Classe + comptage	Détection
c — Couloir dégagé ou obstrué	État	Occupation LiDAR + suivi
d — Ascenseur disponible	État composite	Détection + logique (voir §4, E3)
e — Trajectoire libre ou bloquée	État	Suivi + projection des vitesses
f — Niveau de confiance	Scalaire [0,1]	Calibration (§6)

La sortie **f** est la plus exigeante : le score brut d'un détecteur n'est pas une probabilité. Les réseaux modernes sont sur-confiants — un lot de détections à 0,9 est empiriquement juste à environ 70 %. La livrer telle quelle à l'IA de décision serait une faute.

2. La contrainte qui commande tout : le Raspberry Pi 5

Caractéristique	Conséquence directe
4 × Arm Cortex-A76 @ 2,4 GHz	Pas de GPU ni de NPU : toute l'inférence est sur CPU
Instructions NEON dot-product	L'INT8 est réellement accéléré (× 2,1 mesuré sur A76) — contrairement au Cortex-A53 du Pi 3, où l'INT8 est 1,76 × plus lent . Le choix du Pi 5 n'est donc pas neutre
~7-12 W en charge, throttling sans dissipateur	Le refroidissement fait partie du protocole de mesure

Le budget de latence — transformer « temps réel » en un seuil opposable

VA à 1,0 m/s croisant un piéton à 1,4 m/s → rapprochement à 2,4 m/s. Avec une décélération confortable de 1 m/s² (charge fragile : prélèvements, médicaments) et 0,5 m de marge, la portée de détection utile est d'environ **4 m**. En visant une boucle à 10 Hz, dont ~45 ms sont consommés par l'acquisition, le pré-traitement et la fusion :

Budget d'inférence : ≤ 50 ms par image, soutenu, à température stabilisée

soit 10 Hz de cadence de perception et 10 cm parcourus par cycle.

Latence d'inférence (Pi 5, 4 threads, à chaud)	Verdict
≤ 50 ms	Confortable — marge pour la fusion et le suivi
50 – 100 ms	Acceptable
100 – 200 ms	Limite — impose de ralentir le VA ou d'ajouter un accélérateur
> 200 ms	Éliminatoire en environnement partagé avec des piétons

3. État des lieux de l'existant

La logistique hospitalière autonome est un marché **mature**, pas un domaine émergent.

Système	Capteurs	Calcul	IA de perception	Ascenseur
Aethon TUG (prod. depuis ~2004)	LiDAR + ultrasons + IR, puis caméra de profondeur RealSense	x86 embarqué	SLAM au cœur ; la caméra est arrivée en dernier , en complément	Réseau
Panasonic HOSPI (prod. depuis ~2013)	Capteurs multiples, multi-hauteurs	Embarqué	Évitement + carte pré-établie. Certifié ISO 13482	Réseau
Relay Robotics	LiDAR + profondeur + ultrasons	Embarqué	Navigation en environnement public encombré	Réseau
Diligent Moxi	LiDAR + caméras multiples	Embarqué haute perf.	Perception + manipulation + interaction sociale	Réseau
ORB — Carnegie Mellon, IEEE CASE 2025	Multimodaux (base Fetch)	GPU	YOLOv7 + SAM 2 + Grounding DINO , ROS 2, arbres de comportement	—
Prototypes Raspberry Pi (académiques)	Caméra seule le plus souvent	Raspberry Pi 3/4/5	YOLOv8 / v10 / v12n seul — 6 à 8 FPS	—

Les trois régimes sont nets : l'industrie résout le problème **en y mettant le matériel nécessaire** ; la recherche **en y mettant un GPU** ; les prototypes bas coût s'arrêtent à la détection brute, sans structuration ni quantification de l'incertitude.

4. Quatre enseignements, et ce qu'ils imposent

	Enseignement	Ce qu'il impose à notre projet
E1	La géométrie d'abord, la sémantique ensuite. Aucun système en production ne fonde sa navigation sur la caméra : tous partent de la télémétrie et ajoutent la vision par-dessus	Le LiDAR 2D fournit la distance métrique et l'espace libre pour un coût CPU nul . La profondeur monoculaire apprise (MiDaS, Depth Anything) est écartée : elle doublerait le budget d'inférence pour une sortie non métrique
E2	La sécurité des personnes ne passe pas par l'IA. ISO 3691-4 exige un niveau PLd (ISO 13849) pour la détection de personnes — redondance, détection de défaut. Aucun réseau de neurones ne peut y prétendre : il est statistique, pas déterministe	Dans tous les systèmes commerciaux, un scanner laser certifié garantit l'arrêt ; l'IA sert à <i>comprendre</i> la scène. Notre module est un démonstrateur de perception, pas un organe de sécurité — à écrire explicitement. En contrepartie, le déterminisme de la latence et l' honnêteté de la confiance deviennent des critères de premier rang
E3	Ce qui est connu par le réseau ne doit pas être deviné par un capteur. HOSPI et Relay obtiennent l'état de l'ascenseur par requête réseau — exacte, instantanée, fiable à 100 %	La sortie <i>d</i> est mal posée comme problème de vision. Point à arbitrer (\$8)
E4	Sur Raspberry Pi, 6-8 FPS est le régime naturel d'un YOLO non optimisé — soit sous notre cible . Les revues convergent sur un triptyque : quantification, élagage, architectures légères	L'effort doit porter sur la chaîne d'exécution , pas sur l'architecture du modèle (\$5)

5. Comparaison des modèles de détection

5.1 Les candidats

Modèle	Type	Params	mAP COCO	Sans NMS	Latence Pi 5 (640 px)	Verdict
SSD-MobileNetV2 / EfficientDet-Lite	CNN à ancres	3-5 M	22-32	non	—	Écarté : 8 à 17 points de mAP sous un YOLO nano moderne
NanoDet-Plus-m	CNN sans ancres	~1,2 M	~27	non	~20-30 ms (416, INT8, est.)	Repli : le plus frugal (980 Ko en INT8), mais peu maintenu depuis 2022
YOLOv8n	CNN sans ancres	3,2 M	37,3	non	~258 ms (NCNN)	Écosystème très mûr
YOLO11n	CNN sans ancres	2,6 M	39,5	non	~80 ms (NCNN)	Repli n° 1 : export NCNN le plus éprouvé
YOLO26n (janv. 2026)	CNN sans ancres	2,4 M	40,9	oui	~67 ms (NCNN)	Retenu
RF-DETR-Nano / D-FINE	Transformeur	—	meilleure précision	oui	non documentée	Écarté pour l'embarqué : conçus pour GPU, attention mal servie par un CPU ARM. Réutilisés hors ligne comme modèle enseignant et auto-annotateur

Chiffres issus de la littérature, très dispersés selon la résolution, le nombre de threads et le refroidissement. Ils servent à classer et éliminer, pas à dimensionner : la mesure interne reste à produire (\$7).

5.2 Les deux résultats qui décident

1. Le format d'export pèse plus lourd que le choix du modèle. Passer de PyTorch à NCNN sur YOLO11n fait passer la latence de ~400 ms à ~80 ms — **un facteur 5**. Aucun changement d'architecture du tableau n'offre un tel gain.


Technique	Gain	Priorité
Export NCNN (runtime ARM de Tencent)	× 3 à × 5	1
Résolution 640 → 416	× 2,4	2
Quantification INT8 (dot-product du A76)	× 2,1	3
Cumul estimé	≈ × 15, soit ~400 ms → 25-30 ms	—

2. YOLO26n est préféré pour une raison qualitative, pas pour son mAP. Son avantage de +1,4 point sur YOLO11n est secondaire face au facteur 5 ci-dessus. Ce qui le départage, c'est l'architecture **sans NMS** : le coût du *Non-Maximum Suppression* dépend du nombre de détections dans l'image — rapide dans un couloir vide, lent dans un hall bondé, c'est-à-dire **au pire moment**. Sans NMS, la latence est déterministe. C'est exactement ce qu'exige l'enseignement E2.

6. Le choix retenu

Principe directeur : un seul réseau de neurones dans la boucle

Toutes les autres fonctions — distance, suivi, état, confiance — sont assurées par des méthodes géométriques ou statistiques à coût quasi nul, exploitant des capteurs déjà présents au cahier des charges. C'est ce qui permet de tenir simultanément les trois familles de critères (performance, frugalité, embarqué), là où un empilement de réseaux spécialisés saturerait le CPU.



Brique	Choix	Argument décisif
Détection	YOLO26n, NCNN INT8, 416×416	Meilleur score multicritère (4,10/5) ; latence déterministe (sans NMS)
Distance	Fusion caméra / LiDAR 2D par secteur angulaire	Métrique, ~6 cm d'erreur rapportés, coût CPU nul
Espace libre	Occupation LiDAR 2D	Un obstacle de classe inconnue devient « une zone qui n'est pas du sol » — filet de sécurité par construction, sans second réseau ni annotation pixel
Verre et sas	Sonar	Seul capteur voyant les surfaces vitrées, invisibles au LiDAR et à la caméra
Suivi	ByteTrack + ego-motion IMU	Coût nul ; conserve les détections à faible score → gain de rappel sur « personne » . L'IMU remplace gratuitement la compensation visuelle de BoT-SORT
Confiance	Temperature scaling + agrégation temporelle + accord inter-capteurs	Coût d'inférence nul ; répond à la sortie <i>f</i> . MC-Dropout et ensembles écartés (coût × N passes)
Matériel	CPU nu ; AI Kit Hailo-8L documenté en repli mesuré	La frugalité est un critère d'évaluation du sujet — y répondre avec un accélérateur à 70 € serait répondre à côté

7. Ce qui reste à prouver

L'état de l'art **oriente**, il ne prouve pas. Trois travaux à mener avant de figer le choix.

① **L'expérience prioritaire — courbe résolution / rappel.** À mener **avant tout entraînement long** : tracer le rappel sur la classe « personne » en fonction de la résolution d'entrée (640 / 512 / 416 / 320), croisé avec la distance.

- L'hypothèse à tester : en couloir hospitalier (2-3 m de large), les obstacles pertinents sont **proches donc grands dans l'image**. La pénalité de la réduction de résolution devrait y être bien plus faible que sur COCO, dont la métrique est dominée par les petits objets.
- Si le rappel tient à 416, **la faisabilité sur CPU nu est acquise**. Sinon, il faut arbitrer entre ralentir le VA, accepter 5-7 Hz, ou basculer sur le Hailo-8L. **Le savoir en semaine 4 plutôt qu'en semaine 20 est la meilleure réduction de risque du projet.**

② **Le banc de mesure sur Pi 5.** 3 modèles × 4 formats × 3 résolutions. Conditions imposées : 10 min de chauffe, dissipateur actif, 1 000 images, report de la **médiane et du p95** (pas de la seule moyenne), relevé de température, de throttling et de consommation. Aucun des travaux Raspberry Pi recensés ne publie ces éléments — c'est un espace de contribution réel.

③ **Le jeu de données.** Collecte en couloirs, halls d'ascenseur et sas, de jour **et de nuit**, avec floutage des visages à la source (RGPD, secret médical). Classes absentes de COCO à annoter : brancard, chariot de soins, pied à perfusion, porte d'ascenseur, personne au sol. Pré-annotation par RF-DETR ou D-FINE **hors ligne**, puis correction manuelle.

Critères de réussite proposés

Critère	Seuil
Rappel classe « personne » @ IoU 0,5	≥ 95 %
mAP@0,5 toutes classes	≥ 60 %
Latence médiane / p95 sur Pi 5	≤ 50 ms / ≤ 100 ms
Taille du modèle déployé	≤ 15 Mo
Puissance système	≤ 8 W moyens
Calibration de la confiance (ECE)	≤ 0,05

8. Points à arbitrer — questions pour la réunion

1. **Périmètre capteurs.** Le GPS est inopérant en intérieur ; le RFID et le BIR relèvent de la localisation symbolique, pas de la perception géométrique. Les traite-t-on, ou sont-ils hors périmètre ?
2. **Vitesse nominale du VA.** Elle conditionne tout le budget de latence du §2.
3. **LiDAR disponible : 2D ou 3D ?** L'écart de complexité entre les deux est d'un ordre de grandeur.
4. **L'AI Kit (Hailo-8L) est-il autorisé au budget,** ou la démonstration doit-elle rester sur CPU nu ? Cela change la réponse de l'état de l'art.
5. **Accès terrain** pour la collecte du jeu de données, et cadre RGPD associé.
6. **Ascenseur : interface réseau accessible ?** (cf. E3) Sinon, la sortie d se dégrade en une estimation visuelle nettement moins fiable.

Point de licence à signaler. YOLO26 et YOLO11 sont sous **AGPL-3.0** : compatible avec un PRI académique publié en dépôt ouvert, mais bloquant en cas de valorisation industrielle fermée. Dans ce cas, **RF-DETR**, **D-FINE** et **NanoDet (Apache 2.0)** deviendraient structurellement préférables. Ce n'est pas un détail : c'est un critère de choix à part entière.

Sources principales

Bibliographie complète (une cinquantaine de références) dans le rapport détaillé.

- **Systèmes en production** — Aethon TUG / Intel RealSense · Panasonic HOSPI, certification ISO 13482 · Relay Robotics, intégration ascenseur · Diligent Moxi
- **Recherche** — ORB: Operating Room Bot (arXiv 2509.15600, IEEE CASE 2025) · Edge AI in Practice: Survey and Deployment Framework (MDPI Electronics)
- **Modèles** — Ultralytics YOLO26 · YOLO26: NMS-Free End-to-End Framework (arXiv 2601.12882) · RF-DETR (arXiv 2511.09554) · ByteTrack / BoT-SORT — comparatif MOT
- **Embarqué** — Is INT8 Portable? Cross-Platform Study (arXiv 2609.16085) · YOLO on Raspberry Pi — benchmarks
- **Normes et briques** — ISO 3691-4:2020 · Nav2 — Costmap 2D